

Conectando Mundos com IA Multimodal

1

A **IA multimodal** combina diferentes tipos de dados, explora suas conexões e integra suas interações para gerar respostas mais completas e precisas.

Os **LLMs multimodais** integram dados usando três tipos de fusão:

- **Precoce:** combinam os dados logo no início;
- **Intermediária:** processam separadamente e integram no meio do processo;
- **Tardia:** juntam os resultados no final, após processar cada tipo de dado isoladamente.



As **aplicações dos LLMs Multimodais** incluem diagnósticos médicos mais precisos, com dados integrados, e ensino interativo, com adaptação em tempo real a múltiplas formas de conteúdo.

Principais Ferramentas de Grandes Modelos de Linguagem Multimodal:

- [GPT-4o](#)
- [Gemini](#)
- [InternVL](#)
- [LLava](#)
- [Claude 3.5](#)
- [Qwen VL](#)

2

Exemplo de uso em campanhas de marketing:



- **Refrigerante:** O MLLM ajudou a criar e adaptar slogans para diferentes públicos na campanha de marketing.
- **Carro:** o modelo forneceu uma série de opções criativas e eficazes, e gerou slogans criativos que contribuíram para o sucesso do lançamento do carro compacto no Brasil.



Exemplo de uso em viagens:

- **Tradução:** O MLLM ajudou a entender cardápios e placas em outros idiomas, como japonês e alemão.
- **Guia turístico:** O MLLM atuou como guia virtual, enriquecendo a visita de Pierre com informações sobre a história e cultura da Praça dos Três Poderes.

O MLLM também pode auxiliar em aplicações como:

- Como cuidar da sua Planta;
- sugestão de Receitas;
- exemplo de Posicionamento para Gravação;
- ajuda na leitura de um gráfico.

3

API Multimodal Live para Google Gemini:

- A Gemini 2.0 permite interações mais naturais, integrando áudio, câmera e outros recursos, e está disponível no Google AI Studio e na API Gemini.

Voice Mode do ChatGPT:

- Permite conversas por áudio com o ChatGPT e está disponível para usuários dos planos *Plus*, *Teams*, empresariais e educacionais.



Alguns exercícios para revisão:

- 1 -** Como a combinação da compreensão de texto, imagem e som nos MLLMs cria experiências mais ricas e interativas?
- 2 -** De que maneira a integração de voz em MLLMs pode ampliar o acesso à tecnologia para pessoas com deficiência visual ou dificuldades de leitura?
- 3 -** Como os recursos de conversação por voz em MLLMs poderiam ser aplicados em ambientes educacionais?
- 4 -** Dê exemplos de como essa integração multimodal pode ser utilizada em cenários práticos, como navegação, compras *online* ou suporte técnico.

4

O **curso** abordou como os princípios de heterogeneidade, conexões e interações permitem que IAs integrem texto, imagem, áudio e vídeo para gerar respostas mais precisas e contextuais.

A **integração de múltiplas modalidades** pode enriquecer a experiência do usuário e automatizar processos complexos de maneira eficaz.



Mesmo diante dos avanços e benefícios apresentados, a IA multimodal ainda enfrenta **desafios** significativos, tanto do ponto de vista técnico quanto ético.

Refleta sobre o imenso potencial que a integração de diversas fontes de dados oferece para transformar a interação entre humanos e máquinas.



Convidamos você a se engajar nesse campo dinâmico, explorar novas ideias e a contribuir para a construção de um futuro no qual a tecnologia não apenas automatize tarefas, mas também enriqueça a experiência humana de maneira ética e sustentável.